Анализ временной динамики речевых сигналов для выявления интеллектуальных способностей человека: отчёт о текущем состоянии проекта `voice_signals`

23 октября 2026 г.

Аннотация

Отчёт описывает текущее состояние реализации проекта `voice_signals` — исследовательского программного инструмента для детекции речевой активности (VAD) и анализа нелинейной временной динамики речевого сигнала методом модифицированного нормированного размаха (modified R/S, методика Кузенкова и Логинова, 2014). Представлены: цель работы и научная гипотеза, обзор методической базы, архитектура и состав реализованного программного обеспечения, результаты пилотных вычислительных экспериментов на синтетических данных и на одной тестовой записи, обнаруженные методические ограничения (зависимость оценок показателя Хёрста H и характерного времени T от длины анализируемого сегмента и от окна огибающей), а также перечень критических блокеров, препятствующих переходу к содержательной научной оценке. Документ подготовлен как основа для обсуждения с научным руководителем: зафиксировано, что сделано, что работает по инженерным критериям, что проверено лишь технически, и какие решения нужны для продолжения работы.

Содержание

1 Введение и постановка задачи **2**
- 1.1 Научная идея . . . 2
- 1.2 Принципиальное разграничение (методологическая позиция) . . . 2
- 1.3 Текущий статус . . . 3

2 Методическая основа: модифицированный R/S-анализ **3**
- 2.1 Классический R/S-анализ . . . 3
- 2.2 Модификация Кузенкова–Логинова . . . 3

3 Архитектура и реализация **4**
- 3.1 Структура пакета . . . 4
- 3.2 Единый слой фрейминга . . . 5
- 3.3 VAD-модуль (Energy VAD) . . . 5
- 3.4 Модуль нелинейной динамики (modified R/S) . . . 5
- 3.5 Контракты данных . . . 6
- 3.6 Вспомогательный инструментарий . . . 6
- 3.7 Воспроизводимость . . . 7

4 Тестирование **7**

5 Вычислительный эксперимент на тестовой записи **7**
5.1 Базовый прогон VAD 7
5.2 Обнаруженная методическая проблема: смещение оценок длиной сегмента . . 7

6 Обзор дополнительной литературы **8**

7 Критические ограничения и блокеры **9**
7.1 Блокер 1: отсутствие реального речевого корпуса 9
7.2 Блокер 2: отсутствие золотой (gold) разметки 9
7.3 Блокер 3: отсутствие baseline WebRTC VAD 9
7.4 Блокер 4: отсутствие разбиения по респондентам (subject-level split) 9
7.5 Методическое ограничение, выявленное экспериментально 9

8 Вопросы к научному руководителю **10**
8.1 Критически важные 10
8.2 Методические 10
8.3 Технические 11

9 Заключение **11**

1. Введение и постановка задачи

1.1. Научная идея

Работа развивает гипотезу о том, что временная структура речевого сигнала человека (чередование речевых и паузальных участков, их статистические характеристики) связана с его когнитивными/интеллектуальными способностями. Методической основой служит модифицированный метод нормированного размаха (R/S-анализ), предложенный в статье Н. П. Кузенкова и В. М. Логинова [1], где показатель Хёрста H и характерное время T вычисляются по огибающей мощности речевого сигнала и используются для различения речевых патологий неврологического генеза (афазии, дизартрии) от нормы.

Проект `voice_signals` является инструментальным слоем для этой гипотезы. Он решает три последовательные инженерные подзадачи:

1. **Сегментация речи** (VAD) — отделение речевых участков от пауз, хезитаций и артефактов;
2. **Расчёт нелинейных динамических признаков** (H, T, в перспективе DFA-оценка Хёрста, показатель Ляпунова, энтропийные меры) на найденных речевых сегментах;
3. **Проверка связи признаков с результатами когнитивных тестов** — отложена до накопления реального корпуса с разметкой.

1.2. Принципиальное разграничение (методологическая позиция)

В правилах проекта зафиксировано явное разделение технической и содержательной задачи:

Модель сегментирует речевые события. Полученные признаки могут использоваться для дальнейшего исследования ассоциаций с результатами когнитивных тестов.

То есть на текущем этапе VAD и расчёт H/T **не интерпретируются** как модель интеллекта или когнитивного состояния — это сознательное ограничение, принятое для методологической чистоты. Любые клинические или когнитивные выводы статьи [1] не переносятся на проект автоматически.

1.3. Текущий статус

На момент подготовки отчёта (23.10.2026) завершены две итерации разработки (v0.1.0 и v0.2.0). Инженерная база функциональна и покрыта тестами, но **отсутствует доступ к реальному речевому корпусу с разметкой**, что является главным блокером перехода от инженерной проверки работоспособности к научной оценке качества и к проверке целевой гипотезы.

2. Методическая основа: модифицированный R/S-анализ

2.1. Классический R/S-анализ

Для временного ряда $x(t_i)$ на интервале длины τ классический R/S-анализ использует:

$$\bar{x}(\tau) = \frac{1}{\tau}\sum_{i=1}^{\tau} x(t_i) \qquad \text{(среднее)} \tag{1}$$

$$S(\tau) = \sqrt{\frac{1}{\tau}\sum_{i=1}^{\tau}\big(x(t_i) - \bar{x}(\tau)\big)^2} \qquad \text{(стандартное отклонение)} \tag{2}$$

$$X(t,\tau) = \sum_{j=1}^{t}\big(x(j) - \bar{x}(\tau)\big) \qquad \text{(накопившееся отклонение)} \tag{3}$$

$$R(\tau) = \max_{1\le t\le\tau} X(t,\tau) - \min_{1\le t\le\tau} X(t,\tau) \qquad \text{(размах)} \tag{4}$$

Эмпирический закон Хёрста:

$$\frac{R(\tau)}{S(\tau)} = \left(\frac{\tau}{2}\right)^{H}, \tag{5}$$

где H — показатель Хёрста. Интерпретация: $H = 0.5$ соответствует броуновскому движению (отсутствие памяти), $0.5 < H < 1.0$ — персистентному процессу (тренды сохраняются), $0 < H < 0.5$ — антиперсистентному (возврат к среднему).

Классическая схема имеет три проблемы: экспоненциальный рост плотности отсчётов при равномерном переборе τ в логарифмической шкале, чувствительность к начальной фазе сигнала и вычислительную сложность $O(N^2)$.

2.2. Модификация Кузенкова–Логинова

В [1] предложена модификация:

- шкала τ строится как геометрическая прогрессия $\tau_1 = 3,\ \tau_i = a\,\tau_{i-1}, a = (N/3)^{1/(n-1)}$ — равномерный шаг в логарифмических координатах;

- ряд разбивается на k пересекающихся интервалов, R/S усредняется по ним — снижается зависимость от фазы;
- вычислительная сложность снижается до $O(n \cdot N)$;
- в качестве исходного ряда берётся *огибающая* речевого сигнала — среднеквадратичное отклонение в скользящем окне (в оригинальной работе 100 мс при частоте дискретизации 8 кГц);
- зависимость $\ln(R/S)$ от $\ln(\tau/2)$ аппроксимируется кусочно-полиномиальной функцией для оценки характерного времени T — момента смены режима (перехода от одного наклона к другому).

В клиническом исследовании [1] (429 образцов, суммарно 23 ч 56 мин записи, рассказ А. П. Чехова «Злой мальчик», чтение и пересказ) получены оценки, сведённые в таблицу 1.

Таблица 1: Статистические характеристики H и T по группам (из [1])

Группа	Корр.	H (ср.)	H (СКО)	T (ср., с)	T (СКО)
Афазия, чтение	-0.643	0.989	0.00488	1.21	0.403
Афазия, пересказ	-0.610	0.990	0.00509	1.06	0.642
Дизартрия, чтение	-0.686	0.988	0.00511	1.33	0.532
Дизартрия, пересказ	-0.405	0.988	0.00488	0.966	0.638
Норма, чтение	-0.850	0.990	0.00289	0.902	0.259
Норма, пересказ	-0.852	0.991	0.00384	0.934	0.497
Нейродин. афазия, чтение	-0.289	0.985	0.00593	1.28	0.467
Нейродин. афазия, пересказ	-0.391	0.984	0.00671	0.997	0.576

Статья показывает приблизительно линейную связь $T \approx \alpha\,(1 - H)$ (уравнения регрессий $T = -kH + b$ для каждой группы) и использует рандомизационный тест (5000 итераций) для проверки значимости различий с нормой: достоверные различия ($p < 0.05$) выявлены для дизартрии и нейродинамической афазии, тогда как моторная афазия в режиме монолога статистически близка к норме.

Важно для дальнейшего обсуждения: во всех группах H лежит в узком диапазоне 0.984–0.991, то есть основная различающая переменная — T, а не H. Это наблюдение существенно для интерпретации собственных результатов проекта (раздел 5).

3. Архитектура и реализация

Проект реализован как локальный Python-пакет `voice_signals` (версия 0.2.0, вторая итерация завершена 17.10.2026) с минимальными зависимостями: единственная внешняя библиотека — `pyyaml`; NumPy, SciPy, PyTorch, librosa не используются. Все алгоритмы написаны на чистом Python и детерминированы.

3.1. Структура пакета

```
voice_signals/
  src/voice_signals/
    vad.py # EnergyVad: энергетическийVAD сгистерезисом
    vad_backend.py # УнифицированныйинтерфейсVadBackend
    dynamics.py # modified R/S: Hurst H, характерноевремяT
```

```
  framing.py # Единаявременнаясетка, RMSогибающая–
  schemas.py # Контрактыданных(SegmentRecord идр.)
  config.py # YAMLконфигурация–, хэшконфигурации(SHA256)
scripts/ # run_vad.py, run_modified_rs.py, run_audit.py,
               # generate_synthetic.py, extract_features.py,
               # demo_pipeline.py
tests/ # 15 детерминированныхunitтестов– (pytest)
configs/default.yaml
data/{synthetic,real,raw,segments,features}/
docs/, reports/
```

3.2. Единый слой фрейминга

Класс `TimeGrid` (`framing.py`) задаёт общую временную сетку (размер окна и шаг в отсчётах, вычисляемые из миллисекунд и частоты дискретизации) и используется одновременно VAD-модулем и модулем расчёта динамических признаков, что исключает рассинхронизацию временных меток между подсистемами. Функция `compute_rms_frames` вычисляет RMS-огибающую сигнала по этой сетке.

3.3. VAD-модуль (Energy VAD)

Базовый детектор речевой активности `EnergyVad` — энергетический VAD с двухпороговым гистерезисом:

- кадр 20 мс, шаг 10 мс;
- порог входа в речь: превышение энергии над оценкой фона (20-й перцентиль распределения энергии по файлу) на 10 дБ;
- порог выхода из речи: превышение на 6 дБ (гистерезис устраняет дребезг на границе речь/пауза);
- постобработка: отбрасывание речевых фрагментов короче 80 мс, склейка пауз короче 80 мс между соседними речевыми фрагментами.

Алгоритм детерминирован, не использует внешних ML-моделей, и выдаёт список *непересекающихся* сегментов `SegmentRecord` — унифицированного контракта данных, валидируемого функцией `validate_non_overlapping`. Класс наследуется от абстрактного `VadBackend`, что подготавливает единый интерфейс для будущих адаптеров WebRTC VAD и Silero VAD (на момент отчёта не реализованы — есть только интерфейс).

3.4. Модуль нелинейной динамики (modified R/S)

Функция `modified_rs_hurst` (`dynamics.py`) реализует алгоритмическую схему из раздела 2 на энергетической огибающей сигнала:

1. построение огибающей как RMS в скользящем немедленно соседствующем окне (`envelope_window_sec`, по умолчанию 25 мс — отличается от 100 мс в оригинальной статье, см. обсуждение в разделе 5);
2. геометрическая шкала масштабов τ от `min_tau` (по умолчанию 4) до половины длины огибающей;

3. для каждого τ — усреднение R/S по перекрывающимся окнам (шаг $\tau/2$);
4. оценка H как наклон линейной регрессии $\ln(R/S)$ от $\ln(\tau/2)$ (метод наименьших квадратов, без внешних библиотек);
5. оценка качества аппроксимации через R^2; при $R^2 < 0.7$ устанавливается предупреждение `weak_log_log_fit`;
6. оценка характерного времени T двумя методами, управляемыми флагом `use_piecewise_fit` (по умолчанию `True`):
   - `"argmax"` (итерация 01) — τ, максимизирующий усреднённое значение R/S;
   - `"piecewise"` (итерация 02, реализовано в `_piecewise_fit_characteristic_time`) — полный перебор точки излома, минимизирующей суммарный остаток двух независимых линейных МНК-регрессий (левого и правого сегмента на $\ln(\tau/2)$–$\ln(R/S)$); сохранена обратная совместимость.

Результат оформлен как неизменяемая структура `HurstRSResult` с полями `hurst_h`, `characteristic_time_sec`, `tau_values`, `fit_r_squared`, `valid`, `warnings`, `fit_method`. Короткие (< 16 отсчётов) или вырожденные (постоянные) входы дают `valid=False` с явным кодом причины, а не ошибочное число.

3.5. Контракты данных

Пакет `schemas.py` фиксирует общие структуры для всех подсистем: `SegmentRecord` (речевой сегмент с валидацией на непересечение и допустимость метки), `FileAuditRecord` (результат аудита WAV), `FrameFeatureRecord` (метаданные кадровых признаков), `ExperimentRecord` (результат эксперимента с train/val/test-разбиением по респондентам, метриками и хэшем конфигурации). Унификация контрактов предназначена для того, чтобы baseline-детекторы (energy, WebRTC) и будущий собственный VAD возвращали данные в одном формате и были сравнимы.

3.6. Вспомогательный инструментарий

- **Генератор синтетического корпуса** (`scripts/generate_synthetic.py`) — создаёт WAV-файлы с известной (ground truth) разметкой из четырёх типов событий (`speech`, `silent_pause`, `hesitation`, `artifact`), контролируемым отношением сигнал/шум (5/10/20/30 дБ) и известным истинным H (`true_h`) — используется для проверки корректности алгоритмов без доступа к реальным записям;
- **Аудит WAV-файлов** (`scripts/run_audit.py`) — метаданные (частота дискретизации, число каналов, битность, длительность), энергетические характеристики (RMS, пик, crest factor, уровень шума) и флаги качества (клиппинг, низкая энергия, почти полная тишина, нестандартная частота дискретизации);
- **Экстрактор кадровых признаков** (`scripts/extract_features.py`) — RMS, энергия в дБ, zero-crossing rate, упрощённая спектральная плоскостность (без FFT-реализации, через отношение дисперсии к максимуму — заявленное ограничение, не полноценный спектральный признак);
- **Демонстрационный конвейер** (`scripts/demo_pipeline.py`) — последовательный прогон: загрузка конфигурации → VAD → modified R/S на найденном сегменте → интерпретация H.

3.7. Воспроизводимость

Конфигурация (`configs/default.yaml`) хэшируется функцией `config_hash` (SHA256) для привязки экспериментов к точному набору параметров. Все алгоритмы детерминированы (повторный запуск даёт идентичный результат — проверено unit-тестом `test_hurst_result_is_deterministic`).

4. Тестирование

На момент отчёта в проекте 15 unit-тестов (`pytest`), организованных в три модуля:

- `test_vad.py` — проверка энергетического VAD на синтетическом тоне (сегментация точно совпадает с границами тона с допуском 20 мс), отбрасывание слишком коротких речевых фрагментов, валидация контракта `SegmentRecord` (отказ при пересечении границ и недопустимой метке), детерминированность `modified_rs_hurst`;
- `test_framing.py` — корректность построения временной сетки, расчёта времён кадров, вычисления RMS-огибающей (включая проверку ожидаемого RMS синусоиды $A/\sqrt{2}$) и детерминированность;
- `test_config.py` — загрузка YAML-конфигурации, детерминизм и чувствительность хэша конфигурации к изменению содержимого, валидация обязательных полей.

Все 15 тестов проходят (`15 passed`). Это подтверждает корректность реализации алгоритмов *относительно их собственной спецификации* на контролируемых синтетических сигналах — не более того: тесты не могут подтвердить качество VAD или релевантность признаков H/T на реальной речи.

5. Вычислительный эксперимент на тестовой записи

5.1. Базовый прогон VAD

На тестовой записи `tests/test_data/Ru-Vegetables.wav` энергетический VAD обнаружил 79 речевых сегментов длительностью от десятков миллисекунд до нескольких секунд (полный список воспроизводимо сохранён в `tests/result1.md` и совпадает между итерациями — подтверждение детерминированности пайплайна). Для первого сегмента (1.29–1.94 с, то есть длительностью 0.65 с) модифицированный R/S-анализ даёт:

$$H = 0.979, \qquad T = 0.250 \text{ с}, \qquad R^2 = 0.995, \qquad \text{fit_method} = \text{”piecewise”}.$$

Высокое значение H ожидаемо и согласуется с [1]: там H во всех клинических группах тоже лежит в диапазоне 0.984–0.991 (таблица 1), поскольку расчёт ведётся не по сырому сигналу, а по гладкой огибающей мощности, которая по построению обладает сильной положительной автокорреляцией.

5.2. Обнаруженная методическая проблема: смещение оценок длиной сегмента

Был проведён дополнительный эксперимент: расчёт H и T на всех 79 найденных речевых сегментах записи. Результаты:

- короткие сегменты дают $H \approx 0.95$–0.99;
- длинные сегменты дают $H \approx 0.69$–0.87;
- корреляция H с длиной сегмента ≈ -0.76;
- корреляция T с числом доступных масштабов $\tau \approx +0.87$ (то есть T фактически воспроизводит длину сегмента, а не является от неё независимой характеристикой).

Рабочая гипотеза причины. Окно огибающей по умолчанию равно 25 мс (в 4 раза короче, чем 100 мс в оригинальной статье), а верхняя граница масштабов τ автоматически устанавливается как половина длины огибающей сегмента — то есть напрямую зависит от длительности входного фрагмента.

Для проверки гипотезы окно огибающей было временно увеличено до 100 мс (как в [1]) и прогон повторён. Результат:

- значения H снизились и стали более разбросанными (≈ 0.4–0.9);
- T приблизилось к диапазону статьи (≈ 0.6–2.0 с);
- сегменты короче ≈ 1.2 с перестали давать валидную оценку (отбрасываются по критерию `len(envelope) < 8`);
- валидную оценку получили 19 сегментов из 79 (24%).

После эксперимента конфигурация возвращена к исходным значениям (25 мс); изменение **не было зафиксировано как постоянное**, это разведочный эксперимент.

Вывод эксперимента (не окончательное решение, а констатация факта для обсуждения с научным руководителем): оценки H и T, получаемые текущей реализацией, **нельзя напрямую сравнивать между сегментами разной длины**, и выбор окна огибающей существенно влияет на результат. Это не ошибка вычислений — качество аппроксимации $R^2 \geq 0.9$ в обоих вариантах, — а методическое ограничение текущей конфигурации пайплайна. Требуется решение: либо нормировать диапазон масштабов τ независимо от длины сегмента, либо зафиксировать единое окно огибающей и минимальную длину анализируемого сегмента по образцу статьи, либо явно учитывать длину сегмента как ковариату при последующем статистическом анализе.

6. Обзор дополнительной литературы

Помимо основной методической статьи [1], для проекта изучены четыре дополнительных источника, конспекты которых хранятся в `docs/books/` и `docs/literature-review-neuroinformatics-2021.md`:

- **Нейроинформатика-2021** — методы оконной детекции событий (YOLOv4+DeepSORT, IoU 78.81%, F1 0.98), упругие карты для валидации на малых выборках через суррогатные данные, спайковые нейросети. Применимо к проекту как источник IoU-метрик для оценки временных сегментов и идеи робастности через суррогатные данные;
- **HAR на видео (AIP 2025)** — типовой конвейер сегментация→признаки→классификация, полу-контролируемое обучение при малой разметке, разделение baseline-признаков и обучаемых представлений;

- **Wireless HAR (AIP 2026)** — явное обоснование важности subject-level (не frame-level) разбиения на train/val/test и deployment- метрик (латентность, размер модели);
- **Emotion recognition на DEAP (AIP 2026)** — спектральные признаки (FFT, band power, spectral entropy) и табличные baseline-модели (XGBoost/RF, accuracy 87–90%), также подтверждает необходимость subject-independent разбиения.

Эти источники не являются основой метода (ей остаётся [1]), но обосновывают инженерные решения, намеченные на следующую итерацию: subject-level split, IoU/F1 метрики с tolerance, табличный baseline поверх классических + нелинейных признаков.

7. Критические ограничения и блокеры

7.1. Блокер 1: отсутствие реального речевого корпуса

Все результаты раздела 5 получены на синтетических данных и на *одной* тестовой записи без подтверждённой клинической или когнитивной разметки. Текущая частота дискретизации 16 кГц, заложенная в конфигурации, помечена в коде как допущение (`ASSUMPTION: sample_rate 16000`) и не подтверждена фактическими данными корпуса. Без реального корпуса невозможны: калибровка порогов VAD, оценка метрик качества, проверка целевой гипотезы о связи H/T с интеллектуальными способностями.

7.2. Блокер 2: отсутствие золотой (gold) разметки

Нет ручной разметки речевых сегментов на реальных данных, соответственно невозможен расчёт precision/recall/F1, невозможна калибровка порогов энергетического VAD и сравнение с baseline-методами на содержательных данных.

7.3. Блокер 3: отсутствие baseline WebRTC VAD

Интерфейс `VadBackend` подготовлен, но промышленный baseline (WebRTC VAD, опционально Silero VAD) не реализован — на данный момент невозможно сравнение собственного подхода с общепринятым решением.

7.4. Блокер 4: отсутствие разбиения по респондентам (subject-level split)

Алгоритм разбиения train/validation/test по идентификатору респондента (а не по кадрам/сегментам) не реализован. Без него любая оценка качества на реальных данных будет методологически некорректной (оптимистично смещённой из-за утечки информации между выборками).

7.5. Методическое ограничение, выявленное экспериментально

Зависимость оценок H и T от длины сегмента и от окна огибающей (раздел 5) требует явного решения перед тем, как эти признаки можно будет использовать для сравнения сегментов разной длительности или для корреляции с когнитивными тестами.

8. Вопросы к научному руководителю

Для продолжения работы требуются решения по следующим пунктам (полный список — 12 пунктов в `docs/questions-for-advisor.md`; ниже — сокращённая версия для обсуждения).

8.1. Критически важные

1. **Реальный корпус.** Когда и как можно получить доступ к реальному корпусу записей? Нужны: минимум 50–100 файлов для пилота (200+ для валидации), параметры записи (частота дискретизации, число каналов, битность, формат), метаданные (`subject_id`, `task_type` — чтение/монолог/ответы на вопросы, возраст, пол, результаты когнитивных тестов).

2. **Разметка.** Согласна ли предложенная таксономия (`speech`, `silent_pause`, `hesitation`, `artifact`; дыхание $\rightarrow$ `artifact`; лексические заполнители не выделяются отдельно)? Кто выполняет пилотную двойную разметку, сколько файлов, какой целевой уровень согласованности (предлагается Cohen's $\kappa \geq 0.8$)?

3. **Правовой статус.** Есть ли этическое одобрение на использование записей? Разрешено ли использовать внешние облачные сервисы ASR/VAD (сейчас действует ограничение `RAW_AUDIO_EXTERNAL_UPLOAD = forbidden_until_legal_review`)? Label Studio — локально или в облаке?

8.2. Методические

1. **Окно огибающей и диапазон масштабов τ.** Какое окно считать корректным — 25 мс (текущее по умолчанию) или 100 мс (как в [1])? Как бороться с зависимостью H/T от длины сегмента (раздел 5): нормировать диапазон τ, фиксировать минимальную длину сегмента, или учитывать длину как ковариату?

2. **Характерное время T.** Достаточен ли реализованный кусочно-*линейный* fit (две независимые прямые с оптимальной точкой излома), или необходима кусочно-*полиномиальная* аппроксимация (линейный слева, квадратичный справа), как указано в оригинальной статье?

3. **Приоритет дополнительных нелинейных признаков.** Достаточно ли на ближайшем этапе довести modified R/S до полной методики (включая сравнение с DFA-оценкой Хёрста), или необходимо сразу вводить показатель Ляпунова, выборочную/перестановочную энтропию и RQA?

4. **Первичная метрика качества VAD.** Оставить ведущей `false_pause_precision`, или пересмотреть набор (контрольные: `speech_recall`, `hesitation_recall`, `pause_duration_bias`; дополнительные: IoU, latency, segment F1 с заданным tolerance)?

5. **Связь с интеллектуальными способностями.** Какие когнитивные тесты планируется использовать для проверки связи (IQ-тесты, тесты рабочей памяти, исполнительных функций, беглости речи)? На каком этапе — после стабилизации VAD или параллельно? Какие конфаундеры контролировать (возраст, образование, нативность языка)?

8.3. Технические

1. Нужен ли WebRTC VAD как обязательный baseline, или достаточно сравнения с energy VAD на первом этапе?

2. Нужен ли Silero VAD (нейросетевой baseline, требует PyTorch) хотя бы как опциональный?

3. Какие форматы аудио ожидать в реальном корпусе (mono/stereo, частота дискретизации, WAV/MP3) — определяет необходимость ресемплинга и downmix, которые сейчас не реализованы.

9. Заключение

Инженерный фундамент проекта реализован в соответствии с методической схемой из статьи [1]: модифицированный R/S-анализ с геометрической шкалой масштабов, усреднением по перекрывающимся окнам и кусочно-линейной оценкой характерного времени T; энергетический VAD с гистерезисом; единые контракты данных и временная сетка; синтетический генератор с известной разметкой для проверки корректности алгоритмов; 15 детерминированных unit-тестов, все проходящие.

Технически инструмент работоспособен и воспроизводим. Однако это подтверждает только *корректность реализации относительно собственной спецификации на контролируемых сигналах* — не качество детекции речи и не релевантность признаков H/T на реальных данных, и тем более не связь с интеллектуальными способностями, которая пока не проверялась ни на каких данных.

Дополнительно, собственный вычислительный эксперимент (раздел 5) выявил, что текущие оценки H и T систематически зависят от длины анализируемого сегмента и от выбора окна огибающей — это методическая проблема, требующая решения прежде, чем признаки можно использовать для содержательного сравнения.

Переход к научно значимым результатам блокирован отсутствием: реального речевого корпуса, золотой разметки, промышленного VAD-baseline и алгоритма разбиения по респондентам. Следующая итерация работы должна начаться с решения этих блокеров совместно с научным руководителем (вопросы в разделе 8); параллельно, без реальных данных, можно вести реализацию WebRTC-адаптера, DFA-Hurst сравнения на синтетике и подготовку инструкции разметки.

Список литературы

[1] Кузенков Н. П., Логинов В. М. *Использование метода нормированного размаха при анализе речевых патологий неврологического генеза.* Компьютерные исследования и моделирование, 2014, т. 6, № 5, с. 775–791.